

1º Entrega Estadística Multidimensional

20221020010 - Ana Laura Morcote
20221020026 - Juan Pablo Mosquera
20221020057 - Juan David Amaya
20221020092 - Hana Sofía Pinilla

Acerca del dataset: Datos iniciales

Link(s):

<https://archive.ics.uci.edu/dataset/350/default+of+credit+card+clients>

Título: Default of Credit Card Clients

Fecha de publicación: 25/01/2016

Descripción: Este dataset contiene datos de pagos crediticios junto con información de las personas que solicitaron el credito en Taiwan en el año de 2005 (desde abril hasta septiembre)

Cantidad de columnas: 25

- # entero: 24
- # flotante y double: 0
- # binario: 1
- # caracter: 0
- # cadena de texto: 0
- # objeto: 0

Cantidad de registros: 30000

Este dataset no presenta ningún nulo en ninguna columna



Acerca del dataset: Columnas

Nombre	Descripción	Tipo de dato original	Tipo de dato real	Valores no definidos y su cantidad
ID	"ID", funge como índice de registro.	Entero	-	No aplica
X1	"LIMIT_BAL", la cantidad del crédito (en nuevo dólar taiwanes). Tanto el crédito individual al consumidor como el crédito familiar (complementario)	Entero	-	No aplica
X2	"SEX", el género de la persona solicitante del crédito (1=hombre; 2=mujer)	Entero	Categorico	No aplica
X3	"EDUCATION", hace referencia al nivel educativo del solicitante del crédito (1=Posgrado; 2=Pregrado; 3=Bachillerato; 4=Otros)	Entero	Categorico	345 registros (1.15% del total) con categorías no documentadas oficialmente (0, 5 y 6). Recodificados a la categoría 4 ("Otros"). "Otros" queda conformada por 468 registros, equivalentes al 1.56% del total
X4	"MARRIAGE", es el estado civil del solicitante del crédito (1=Casado; 2=Soltero; 3=Otros)	Entero	Categorico	54 registros (0.18% del total) con la categoría no documentada 0. Recodificados a la categoría 3 ("Otros"). "Otros" queda conformada por 377 registros, equivalentes al 1.26% del total.
X5	"AGE", es la edad del solicitante del crédito.	Entero	-	No aplica
Y	"default payment next month", es una variable predictiva que predice si un cliente pagará o no su crédito.	Binario	Categorico	No aplica

Acerca del dataset: Columnas

PAY_[Número]: Son columnas que registran el historial de pago en un determinado mes (desde abril hasta septiembre).
Categorías: -1 = pago puntual; 1 = retraso de 1 mes; 2 = retraso de 2 meses; ... ; 9 = retraso de nueve meses
Valores: 0 y -2, no documentados oficialmente, asociados a "sin consumo" o "pago mínimo".

Nombre	Descripción	Tipo de dato original	Tipo de dato real	Valores no definidos y su cantidad
X6	"PAY_0", estado de pago en septiembre	Entero	Categorico	'0': 14737 (49%); '-2': 2759 (9.2%)
X7	"PAY_2", estado de pago en agosto	Entero	Categorico	'0': 15730 (52%); '-2': 3782 (12%)
X8	"PAY_3", estado de pago en julio	Entero	Categorico	'0': 15764 (52%); '-2': 4085 (13%)
X9	"PAY_4", estado de pago en junio	Entero	Categorico	'0': 16455 (54%); '-2': 4348 (14%)
X10	"PAY_5", estado de pago en mayo	Entero	Categorico	'0': 16947 (56%); '-2': 4546 (15%)
X11	"PAY_6", estado de pago en abril	Entero	Categorico	'0': 16286 (54%); '-2': 4895 (16%)

Acerca del dataset:

Columnas

BILL_AMT[Número]: Son columnas que registran el extracto de cuenta (en nuevo dólar taiwanes NT) en un determinado mes (desde abril hasta septiembre).

Nombre	Descripción	Tipo de dato original	Tipo de dato real	Valores no definidos y su cantidad
X12	"BILL_AMT1", extracto en septiembre	Entero	-	No aplica
X13	"BILL_AMT2", extracto en agosto	Entero	-	No aplica
X14	"BILL_AMT3", extracto en julio	Entero	-	No aplica
X15	"BILL_AMT4", extracto en junio	Entero	-	No aplica
X16	"BILL_AMT5", extracto en mayo	Entero	-	No aplica
X17	"BILL_AMT6", extracto en abril	Entero	-	No aplica

Acerca del dataset: Columnas

PAY_AMT[Número]: Son columnas que registran la cantidad del crédito pagada (en nuevo dólar taiwanes NT) en un determinado mes (desde abril hasta septiembre).

Nombre	Descripción	Tipo de dato original	Tipo de dato real	Valores no definidos y su cantidad
X18	"PAY_AMT1", monto pagado en septiembre	Entero	-	No aplica
X19	"PAY_AMT2", monto pagado en agosto	Entero	-	No aplica
X20	"PAY_AMT3", monto pagado en julio	Entero	-	No aplica
X21	"PAY_AMT4", monto pagado en junio	Entero	-	No aplica
X22	"PAY_AMT5", monto pagado en mayo	Entero	-	No aplica
X23	"PAY_AMT6", monto pagado en abril	Entero	-	No aplica

Pre-analisis

Cambios realizados

Eliminación de la columna "ID"

Eliminación de la variable ID para hacer el análisis exploratorio de los datos con la matriz de correlación y exportación del nuevo `datos_credit.csv` sin la columna ID, debido a que el identificador no da un aporte de información al análisis e interpretación de los datos.



Identificación de variables categóricas mal tipificadas

Aunque **credit.xls** almacena todas sus columnas como numeric, varias de ellas son en realidad categóricas y no deberían tratarse como numéricas continuas:

SEX y **MARRIAGE**: categóricas nominales (sin orden entre categorías)
EDUCATION y **PAY_0** a **PAY_6**: categóricas ordinales (con orden, pero sin distancia uniforme entre valores)
default payment next month: binaria/categórica

Esto afecta la interpretación de la matriz de correlación de Pearson calculada, ya que asume variables de intervalo/razón. Queda pendiente para una siguiente etapa del análisis.



Pre-analisis

Selección de “h”


- **Regla de la raíz cuadrada:** el número de bins es igual a la raíz cuadrada del total de observaciones, $K=\sqrt{n}$. Es rápida y útil para conjuntos de datos medianos.
- **Regla de Sturges:** $K=1+3.322\log_{10}(n)$, donde n es el número total de datos.
- **Regla de Freedman–Diaconis:** calcula primero el ancho del intervalo a partir del rango intercuartílico (IQR) y el tamaño de la muestra,

$$h = \frac{2 \cdot \text{IQR}(x)}{n^{1/3}}$$


, y luego deriva el número de bins como $K=(\max(x)-\min(x))/h$. Al basarse en el IQR en vez de en el rango completo, es mucho más robusta ante valores atípicos.





Analisis Univariado: Histogramas y kernel



Sin Zoom




Con Zoom




- Un IQR central pequeño genera anchos de clase muy finos de $h = 2,700$, al dividirse en cientos de bins $K > 250$, las barras se vuelven imperceptibles y el contorno blanco devora el relleno
- Zoom visual sin pérdida de datos (coord_cartesian): Permite enfocar la masa real del 95% de los clientes por ejemplo -20k, 300k en facturación o 0, 50k en pagos sin alterar el cálculo estadístico original
- Al bajar los bins, o aumentar el h , la variable de bill amontonaria la mayoría de datos en una sola barra a la izquierda.
- La concentración en importes bajos o en 0 refleja que una gran proporción de clientes utiliza la tarjeta como medio de pago corriente y no como instrumento de crédito revolving acumulativo.
- El estiramiento del rango hacia el millón de dólares taiwaneses por un pequeño grupo de usuarios expone una alta asimetría en la exposición crediticia de la entidad financiera.


Sin Zoom



Con Zoom



Log







Analisis Univariado: Histogramas y kernel

- La prominente pegada en el origen evidencia un segmento de clientes que no amortiza capital o realiza amortizaciones inferiores a la cuota mínima mensual requerida.
- El pico de la campana coincide con el rango de las cuotas mínimas exigidas por el banco, confirmando que la mayor parte de los usuarios activos cancela montos estándar de mantenimiento de deuda en lugar de amortizaciones totales.
- Escala logarítmica $\log_{10}x+1$ en PAY_AMT Separa el pico de clientes que amortizaron 0 de la distribución continua de quienes sí pagaron.
- Para la estandarizacion logaritmica: La curva revela dos dinámicas financieras superpuestas que la escala original ocultaba: una masa discreta de clientes inactivos o morosos absolutos de abono de \$0 frente a un proceso continuo de amortización para quienes sí transfirieron fondos.

Analisis Univariado: Histogramas y kernel

- La densidad confirma que la mayoría de los clientes se concentra en cupos bajos e intermedios entre 20k y 100k, con una cola decreciente hacia montos mayores.
- A diferencia del histograma, donde los 81 bins dejan huecos intermedios artificiales, el kernel suaviza la distribución y hace visibles crestas secundarias en montos comerciales específicos 200k, 300k y 500k. Esto ocurre porque los bancos asignan líneas de crédito con montos fijos y no de forma continua.
- El histograma con $K = 70$ producía franjas blancas porque el ancho del bin era menor a 1 año y la variable es discreta. La curva de kernel elimina este artefacto y revela una silueta continua unimodal.
- La masa principal se agrupa entre los 25 y 35 años, lo que coincide con la etapa de inserción al mercado laboral formal y la mayor demanda de tarjetas de crédito



Analisis Univariado: Boxplots

En el gráfico original, LIMIT_BAL tiene la caja más grande y parece la variable más dispersa, mientras que las PAY_AMT se ven pequeñas y compactas. Al estandarizar LIMIT_BAL y AGE quedan con las cajas más visibles y atípicos cercanos, esta última en la escala original era una línea; estandarizada muestra su caja y un sesgo leve.


Las cajas de montos se colapsan. BILL_AMT y sobre todo PAY_AMT quedan reducidas a una franja sobre el cero, y sus atípicos se estiran hacia arriba en columnas densas.

Var. compactas: LIMIT_BAL, AGE


¿por qué? La edad tiene límites naturales, y el cupo lo asigna el banco dentro de rangos definidos por política comercial.

Var. dispersas: PAY_AMT1 a PAY_AMT6

¿por qué? La mayoría de clientes hace pagos nulos o mínimos, unos pocos cancelan montos grandes de una vez. Un pago no puede ser negativo, lo que genera la asimetría se va hacia arriba.



muestra quién tiene valores más grandes



muestra quién tiene valores más atípicos respecto de sí mismo

nota: estandarizar divide por la desviación estándar, que es muy sensible a los extremos




Analisis Univariado: Boxplots - Sexo

En los cuatro gráficos las cajas de hombres y mujeres se solapan casi por completo y tienen una forma muy similar; siendo las diferencias de posición y marginales.

Las mujeres tienen un cupo (LIMIT_BAL) ligeramente mayor y los hombres son un poco mayores en edad (AGE). En ambos casos la brecha entre medianas es pequeña frente al rango intercuartílico.

Los montos repiten el patrón general del dataset. Los montos repiten el patrón general del dataset. BILL_AMT y PAY_AMT muestran, dentro de cada sexo, el mismo sesgo a la derecha, cajas comprimidas cerca del cero y colas de atípicos. Los valores más extremos aparecen en el grupo femenino, mas son casos aislados.

SEX no parece ser por sí sola una variable que diferencie el comportamiento crediticio.







Analisis Univariado: Boxplots - Nivel educativo

LIMIT_BAL desciende de posgrado a universidad y a secundaria: la mediana baja y la caja se desplaza hacia abajo; la diferencia más clara de los cuatro gráficos.

La edad se relaciona con la educación, pero no en el mismo orden. Secundaria concentra a los clientes de mayor edad y con más dispersión. Posgrado y universidad tienen perfiles más jóvenes y parecidos entre sí.

BILL_AMT y PAY_AMT mantienen en cada categoría el sesgo a la derecha y las colas de atípicos. Los niveles más altos tienen colas más largas en los pagos, lo que es coherente con cupos mayores. Sin embargo, "Otros" agrupa los códigos no documentados (0, 5 y 6), los cuales tienen pocos casos; por eso sus cajas son más irregulares, con más cupo que secundaria y un estado de cuenta algo más disperso.

EDUCATION diferencia sobre todo el crédito otorgado, más que el comportamiento de facturación o pago.







Analisis Univariado: Boxplots - Estado Civil

Los solteros son claramente más jóvenes y tienen una caja más compacta. Casados y "otros" se ubican en edades mayores, con poco solapamiento entre sus cajas y la de solteros.

El cupo descende de casados a solteros y a "otros". Casados y solteros se solapan bastante (diferencia moderada), mientras que "otros" tiene cupos notablemente más bajos y menos atípicos. Los montos se comportan casi igual en todos los grupos. BILL_AMT y PAY_AMT mantienen, en cada categoría el sesgo a la derecha y las colas de atípicos. "Otros" incluye el código 0 no documentado recodificado y con pocos casos, lo que explica sus colas cortas y su forma distinta.

El estado civil se relaciona con la edad, y la edad arrastra el cupo: los clientes mayores y casados tienden a recibir más crédito.



Analisis Univariado: Boxplots - Estados de Pago

En todos los gráficos se ve que a mayor retraso, menor pago. Hay un corte alrededor de los 2 meses de retraso. Los estados -2, -1 y 0 concentran los pagos más altos y las colas de atípicos más largas.







El estado 2 conserva algunos pagos, con una cola más corta. Desde 3 meses de retraso, los pagos son prácticamente nulos. La diferencia entre estados está en las colas, es decir, en cuántos clientes hacen pagos grandes.

El estado 1 es inconsistente en el tiempo. Casi no existe de abril a julio, aparece en agosto y solo en septiembre forma un grupo con cola amplia, probablemente debido a una anomalía de codificación.

Hay anomalías en -2. Este código significa "sin actividad", pero registra pagos altos (el máximo de agosto está en este grupo). Pueden ser pagos anticipados o problemas de codificación de este valor no documentado.

El estado de pago diferencia claramente los montos pagados. El retraso de 3 meses o más señala clientes que prácticamente dejaron de pagar.

Se está asumiendo que:
0 = pago mínimo
-2 = sin consumo / sin saldo pendiente



```
### Definición de variables, grupos y unidades
```

```
```{r disp_variables_unidades}
```

```
bill_vars <- c("BILL_AMT1", "BILL_AMT2", "BILL_AMT3", "BILL_AMT4",
```

```
payamt_vars <- c("PAY_AMT1", "PAY_AMT2", "PAY_AMT3", "PAY_AMT4",
```

```
Variables monetarias que se graficarán en escala logarítmica (10
```

```
igual que en los histogramas y las densidades de kernel de la S
```

```
vars_log <- c("LIMIT_BAL", bill_vars, payamt_vars)
```

```
unidades <- c(
```

```
 LIMIT_BAL = "NT dólares",
```

```
 AGE = "años",
```

```
 BILL_AMT1 = "NT dólares",
```

```
 BILL_AMT2 = "NT dólares",
```

```
 BILL_AMT3 = "NT dólares",
```

```
 BILL_AMT4 = "NT dólares",
```

```
 BILL_AMT5 = "NT dólares",
```

```
 BILL_AMT6 = "NT dólares",
```

```
 PAY_AMT1 = "NT dólares"
```

# Análisis Bivariado: Preparación de datos


## 1.

Exclusión de variables de identificación y demográficas

## 2.

Agrupación temática de pares: Los pares se organizaron en 8 grupos temáticos, cada uno con su interpretación correspondiente.




# Análisis Bivariado: LIMIT\_BAL vs. AGE







- Relación entre el límite de crédito otorgado (LIMIT\_BAL) y la edad de los clientes (AGE).
- Ligera tendencia creciente del límite de crédito entre los 20 y 30 años
- Entre aproximadamente los 30 y 40 años se presenta una mayor concentración de los valores
- A partir de edades superiores se observa una menor presencia de límites de crédito elevados.
- La mayoría de las observaciones se encuentra por debajo de NT\$500.000, mientras que los valores superiores a este monto presentan una menor frecuencia.

# Análisis Bivariado: LIMIT\_BAL vs. BILL\_AMT

- Relación entre el límite de crédito (LIMIT\_BAL) y los montos de los estados de cuenta (BILL\_AMT) de septiembre a abril.
- Los gráficos presentan un comportamiento generalmente creciente
- La mayoría de los puntos se encuentra por debajo de la diagonal correspondiente a una relación 1:1, lo que indica que los montos registrados en los estados de cuenta son, en la mayoría de las observaciones, inferiores al límite de crédito.
- Alrededor de NT\$500.000 disminuye la concentración de observaciones, debido a la menor presencia de clientes con límites superiores a este valor.






# Análisis Bivariado: AGE vs. PAY\_AMT y BILL\_AMT



- La relación entre la edad de los clientes (AGE) y los montos de pago (PAY\_AMT), así como entre la edad y los montos de los estados de cuenta (BILL\_AMT).
- En los gráficos de AGE vs. PAY\_AMT se observa una alta concentración de los valores de pago en rangos bajos, con una cantidad relativamente reducida de observaciones en valores elevados.
- En los gráficos de AGE vs. BILL\_AMT se presenta una mayor dispersión vertical y una presencia más significativa de valores elevados.
- La mayor concentración de estos valores se encuentra aproximadamente entre los 20 y 50 años, con una presencia notable de montos elevados alrededor de los 30 y 40 años.




# Análisis Bivariado: BILL\_AMT1 y BILL\_AMT2 vs. BILL\_AMT

- La relación entre los estados de cuenta correspondientes a septiembre (BILL\_AMT1) y agosto (BILL\_AMT2) y los estados de cuenta registrados en los demás períodos.
- Asociación positiva entre los montos registrados en diferentes períodos.
- La mayor variación se concentra en los valores cercanos a cero, mientras que los valores más elevados presentan una distribución progresivamente creciente.
- En varios de los gráficos, la relación se encuentra por debajo de una correspondencia 1:1, los valores correspondientes a septiembre y agosto se encuentran, en general, por debajo de los valores de los períodos utilizados como comparación.






# Análisis Bivariado: BILL\_AMT vs. PAY\_AMT

- Relación entre los montos de los estados de cuenta (BILL\_AMT) y los montos de los pagos realizados (PAY\_AMT) en los diferentes períodos.
- No se observa una correspondencia uniforme entre ambas variables, especialmente en los valores elevados de los estados de cuenta.
- En varias de las comparaciones, los pagos permanecen concentrados en valores relativamente bajos incluso cuando los montos de los estados de cuenta presentan valores considerablemente superiores.
- Se identifican algunas combinaciones, en las que se aprecia una mayor proximidad entre los valores de ambas variables.



# Análisis Bivariado: PAY\_AMT vs. PAY\_AMT

- Comparación entre los montos de pago (PAY\_AMT) de diferentes períodos, permitiendo observar su comportamiento entre meses.
- Los gráficos presentan una concentración considerable de observaciones en valores bajos y una menor cantidad de puntos en valores elevados.
- Existe una variabilidad considerable en los montos de pago entre períodos, aunque se mantienen patrones similares de concentración en los valores bajos.



# Variables Seleccionadas

Se seleccionarán todas las variables del dataset:

- LIMIT\_BAL
- SEX
- EDUCATION
- MARRIAGE
- AGE
- PAY\_0 a PAY\_6
- BILL\_AMT1 a BILL\_AMT6
- PAY\_AMT1 a PAY\_AMT6

Excepto:

- ID: Variable que no aporta información relevante para el análisis de los datos, siendo solo un identificador para cada fila
- default payment next month: Variable binaria que no se incluirá, debido a que el análisis principal se realizará mediante PCA, enfocado en las variables utilizadas para analizar la variabilidad del conjunto de datos.



# Gracias por ver

## Estadística Multidimensional

📍 Universidad Distrital Francisco  
José de Caldas – Calle 40

Ingeniería de Sistemas

